

# Stacjonarność

ASC 2024

---

Piotr Żoch

- Regresja pozorną.
- Funkcje ACF i PCF.
- Badanie stacjonarności: testy DF, ADF, KPSS.

## Regresja pozorná

---

- **Regresja pozorna (*spurious regression*):** zmienne  $(x_t, y_t)$  nie mają ze sobą żadnego związku, ale uzyskujemy statystycznie istotnych oszacowania
- Klasyczny przykład: regresja jednej zmiennej niestacjonarnej na drugą, obie to błędzenie losowe.

$$x_t = x_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$y_t = y_{t-1} + \nu_t, \quad \nu_t \sim N(0, \sigma_\nu^2)$$

$$y_t = \beta x_t + e_t$$

- Objawy regresji pozornej:
  - Wysoka wartość statystyki testowej (*p-value* niskie).
  - Wysokie  $R^2$ .
  - Silna autokorelacja reszt.
  - Zmiana wyniku po dodatniu opóźnionej zmiennej objaśniającej (brak statystycznej istotności).

- Dlaczego tak się dzieje?
- Problem:
  - Rozkłady statystyk testowych są niestandardowe (czyli błędem jest badanie istotności zmiennych przy założeniu normalności rozkładu statystyki).
- Estymator OLS nie jest zgodny.
  - nie będzie zbiegać do 0 (prawdziwej wartości w przykładzie powyżej) przy zwiększeniu liczby obserwacji.

## Regresja pozorną: przykład

- Przykład: błędzenie losowe z dryfem

$$X_t = \mu_x + X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$Y_t = \mu_y + Y_{t-1} + \nu_t, \quad \nu_t \sim N(0, \sigma_\nu^2)$$

- Zauważmy, że

$$X_t = \mu_x t + \sum_{k=1}^t \varepsilon_k + X_0$$

$$Y_t = \mu_y t + \sum_{k=1}^t \nu_k + Y_0$$

## Regresja pozorną: przykład

- Mamy

$$\hat{\beta} = \frac{\sum_{t=1}^T x_t y_t}{\sum_{t=1}^T x_t^2} = \frac{\sum_{t=1}^T \left( \mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right) \left( \mu_y t + \sum_{k=1}^t \nu_k + y_0 \right)}{\sum_{t=1}^T \left( \mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right)^2}$$

- Aby to uprościć, użyjemy

$$\frac{1}{T^2} \sum_{t=1}^T t \rightarrow \frac{1}{2}$$

$$\frac{1}{T^3} \sum_{t=1}^T t^2 \rightarrow \frac{1}{3}$$



## Regresja pozorna: przykład

- Mamy

$$\hat{\beta} = \frac{\frac{1}{T^3} \sum_{t=1}^T \left( \mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right) \left( \mu_y t + \sum_{k=1}^t \nu_k + y_0 \right)}{\frac{1}{T^3} \sum_{t=1}^T \left( \mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right)^2}$$
$$\xrightarrow{p} \frac{\mu_y}{\mu_x}$$

- *Uwaga:* w tym przykładzie za regresję pozorną odpowiadały wyrazy zawierające  $t^2$  czyli trend deterministyczny – podobne problemy będziemy mieli przy zmiennych trendostacjonarnych.
- *Uwaga:* podobne problemy występują też w przypadku błędzenia losowego, ale trochę trudniej to pokazać analitycznie.

- Co w przypadku regresji liniowej

$$x_t = \beta y_t + \gamma x_{t-1} + e_t?$$

- Różnica: uwzględniliśmy  $x_{t-1}$  jako zmienną objaśniającą.
- Okazuje się, że to rozwiązuje problem regresji pozornej (wyłumaczenie przy zajęciach dot. kointegracji).
- Praktyczna sugestia: dodać opóźnienia  $x_t$  i  $y_t$  w regresji.

## Funkcje ACF i PACF

---

- **Funkcja autokorelacji** (*Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami

$$\rho_k = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}$$

i  $\rho_k \in [-1, 1]$ .

- Użyliśmy  $\sqrt{\text{Var}(y_t) \text{Var}(y_{t-k})} = \text{Var}(y_t)$  (to wymaga stacjonarności).

- **Funkcja autokorelacji cząstkowej** (*Partial Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami oddalonymi od siebie o  $k$  okresów **bez** uwzględnienia wpływu wszystkich obserwacji “pomędzy”.
- Funkcja ta jest równa wyestymowanemu współczynnikowi  $\alpha_k$  w modelu autoregresyjnym  $k$ -tego rzędu

$$y_t = \mu + \alpha_1 y_{t-1} + \dots + \alpha_k y_{t-k} + \varepsilon_t$$

- Służy do badania autokorelacji reszt z regresji liniowej

$$y_t = \beta_0 + \beta_1 x_{1,t} + \dots + \beta_n x_{n,t} + e_t$$

$$e_t = \rho_1 e_{t-1} + \rho_2 e_{t-2} + \dots + \rho_k e_{t-k} + \varepsilon_t$$

- Wartość statystyki testowej  $nR^2$ , gdzie  $R^2$  jest z regresji pomocniczej

$$\hat{e}_t = \alpha_0 + \sum_{j=1}^n \alpha_j x_{j,t} + \sum_{i=1}^k \rho_i \hat{e}_{t-i} + \varepsilon_t$$

- $H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$ . Rozkład to  $nR^2 \sim \chi_k^2$

$$Q = T(T+2) \sum_{i=1}^k \frac{\hat{\rho}_i^2}{T-i}$$
$$\sim \chi_k^2$$

- $H_0$ : proces jest białym szumem
- Test wykorzystywany przede wszystkim do badania autokorelacji reszt.
- Maddala (2001): test obciążony w kierunku  $H_0$ , niska moc. Breusch-Godfrey preferowany.

# Badanie stacjonarności

---



- Najpopularniejszy sposób badania stacjonarności zmiennych.
- Model:

$$y_t = \beta y_{t-1} + \varepsilon_t$$
$$\varepsilon_t \sim iid(0, \sigma^2)$$

- $H_0$  : proces jest błądzeniem losowym ( $\beta = 1$ ) - niestacjonarność
- $H_1$  : proces jest procesem AR(1) ( $|\beta| < 1$ ) - stacjonarność

# Test Dickey-Fullera

- Model:

$$y_t = \beta y_{t-1} + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma^2)$$

- Odejmując  $y_{t-1}$  od obu stron

$$\Delta y_t = (\beta - 1)y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

- $H_0 : \rho = 0$  - niestacjonarność
- $H_1 : \rho \in (-2, 0)$  - stacjonarność

- **UWAGA:** nie możemy po prostu zastosować OLS i za pomocą statystyki  $t$  zbadać istotność w standardowy sposób.
  - $H_0$ : niestacjonarność. Rozkłady statystyk są niestandardowe!
- Wykorzystujemy specjalne tablice z wartościami krytycznymi dla testu DF.
- Uwaga techniczna: wielkości krytyczne rozkładu statystyki DF są zawsze ujemne.

- Procedura:
  - Regresja  $\Delta y_t$  na  $y_{t-1}$ .
  - Porównujemy statystykę  $t$  z wartościami krytycznymi testu DF:
    - $t$  **poniżej** wartości krytycznej: odrzucamy  $H_0$  (stacjonarność?)
    - $t$  **powyżej** wartości krytycznej: nie odrzucamy  $H_0$  (niestacjonarność?)

- Błądzenie losowe z dryfem

$$y_t = \alpha_1 + \beta y_{t-1} + \varepsilon_t$$

- Trend deterministyczny

$$y_t = \alpha_1 + \alpha_2 t + \beta y_{t-1} + \varepsilon_t$$

- We wszystkich powyższych przypadkach  $H_0$  to też niestacjonarność.

## Rozszerzony test DF (ADF)

- Reszty z regresji

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

często wykazują silną autokorelację.

- Rozszerzony test DF (augmented DF)

$$\Delta y_t = \rho y_{t-1} + \sum_{i=1}^k \gamma_i \Delta y_{t-i} + \varepsilon_t$$

gdzie  $k$  jest dobrane tak, żeby wyeliminować autokorelację reszt.

- Procedura:
  - Regresja  $\Delta y_t$  na  $y_{t-1}$ .
  - Sprawdzamy autokorelację reszt (test Breuscha-Godfrey, nie Durbina-Watsona).
  - Jeśli jest, dodajemy opóźnioną różnicę  $\Delta y_{t-2}$  do specyfikacji i powtarzamy.
  - W przeciwnym wypadku:
    - $t$  **poniżej** wartości krytycznej: odrzucamy  $H_0$  (stacjonarność?)
    - $t$  **powyżej** wartości krytycznej: nie odrzucamy  $H_0$  (niestacjonarność?)

- Reszty z regresji

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

często wykazują silną autokorelację.

- Rozszerzony test DF (augmented DF)

$$\Delta y_t = \rho y_{t-1} + \sum_{i=1}^k \gamma_i \Delta y_{t-i} + \varepsilon_t$$

gdzie  $k$  jest dobrane tak, żeby wyeliminować autokorelację reszt.



- Perron (1989) pokazał, że test ADF ma problemy z odrzuceniem hipotezy zerowej o występowaniu pierwiastka jednostkowego w przypadku zmiany strukturalnej.
- Dla przykładu: proces typu

$$y_t = \beta D_t + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma^2)$$

$$D_t = \begin{cases} 0 & t < t^* \\ 1 & t \geq t^* \end{cases}$$

- Perron (1989) sugeruje modyfikację testu ADF

$$\Delta y_t = \rho y_{t-1} + \sum_{i=1}^k \gamma_i \Delta y_{t-i} + \beta D_t + \varepsilon_t$$

- Wymaga to znajomości daty zmiany strukturalnej.
- Modyfikacja: Andrews i Zivot (2002) – poszukiwaniem takiej daty zmiany strukturalnej, że moc testu jest największa.

- Model:

$$y_t = x_t + z_t$$

$$x_t = x_{t-1} + v_t$$

$$z_t = \mu_0 + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma_\varepsilon^2)$$

$$v_t \sim iid(0, \sigma_v^2)$$

- $H_0 : \sigma_v^2 = 0$  - stacjonarność
- $H_1 : \sigma_v^2 > 0$  - niestacjonarność

- Procedura:
  - Regresja  $y_t$  na stałą (+ ew. trend deterministyczny).
  - Obliczyć sumy  $S_t = \sum_{j=1}^t e_j$  dla  $t = 1, 2, 3, \dots, T$ , gdzie  $e_j$  to reszty z regresji powyżej.
  - Statystyka testowa:  $KPSS = \frac{1}{T^2} \frac{\sum_{t=1}^T S_t^2}{\hat{\sigma}^2}$  gdzie  $\hat{\sigma}^2$  to długookresowa wariancja reszt.

# Testowanie (nie)stacjonarności

- W przypadku małej próby i procesów o wysokim stopniu persystencji:
  - Test ADF: niska moc.
  - Test KPSS: zaburzenia rozmiaru.
- Przykład: jak odróżnić proces trendostacjonarny

$$y_t = \alpha t + \epsilon_t$$

od błędzenia losowego z dryfem

$$\begin{aligned} y_t &= \mu + y_{t-1} + \epsilon_t \\ &= y_0 + \mu t + \sum_{i=0}^t \epsilon_{t-i} \end{aligned}$$

- Czy to, czy proces jest stacjonarny czy niestacjonarny, ma znaczenie?
- Teoria ekonomii może być bardziej pomocna od testów statystycznych...

- Jaki test wybrać? Jakie deterministyczne regresory uwzględnić?
- Problem:
  - dodatkowe deterministyczne komponenty w regresji, które są nieobecne w procesie generującym dane, redukują stopnie swobody i obniżają moc testu stacjonarności.
  - pominięcie deterministycznych komponentów w regresji, które są obecne w procesie generującym dane, obniża moc testu.

